

Nombre Victor Alejandro Chavez Valadez

Práctica 1.1 — Probabilidad y Estadística

Análisis de la evolución poblacional mundial

Objetivo

Utilizar un conjunto de datos real para comprobar el funcionamiento del entorno de análisis de datos y aplicar medidas estadísticas descriptivas básicas utilizando Pandas y NumPy.

Actividad 1 — Identificación de la fuente

Propósito

Reconocer la procedencia del conjunto de datos antes de utilizarlo y documentar correctamente su fuente.

Cita de la fuente

Los datos utilizados en esta práctica provienen de **Our World in Data (OWID)**. La fuente original es **United Nations, World Population Prospects (2024)**.

Cita:

UN, World Population Prospects (2024) – processed by Our World in Data.
“Annual change in population – UN WPP” [dataset]. United Nations,
“World Population Prospects”; United Nations, “World Population
Prospects - Interim Update” [original data].

Preguntas

1. **¿Quién produjo originalmente los datos?**

Los datos fueron producidos originalmente por la **Organización de las Naciones Unidas (United Nations - UN)** a través de su publicación *World Population Prospects (2024)*.

2. **¿Qué organización los procesa para su utilización en Our World in Data?**

La organización **Our World in Data (OWID)** procesa, estandariza y publica los datos para su análisis y visualización.

3. **¿Qué representa la variable que analizarás?**

La variable `Annual change in population` representa el cambio o variación neta anual de la población (diferencia entre la población estimada al 1 de julio de dos

años consecutivos), calculada a partir de los nacimientos, defunciones y saldos migratorios.

Actividad 2 — Carga y exploración de datos

Propósito

Comprobar que el entorno de Python, Pandas y Jupyter funciona correctamente y realizar una primera exploración del dataset.

2.1 Importar las bibliotecas

```
In [1]: import pandas as pd
import numpy as np
```

2.2 Cargar el archivo CSV

```
In [2]: # Cargar el dataset de crecimiento anual de población
path = "../data/raw/annual-population-growth/annual-population-growth.csv"
df = pd.read_csv(path)
```

2.3 Explorar el DataFrame

```
In [3]: # Primeras filas
df.head()
```

```
Out[3]:
```

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
0	Afghanistan	AFG	1951	103163.0	NaN
1	Afghanistan	AFG	1952	108441.0	NaN
2	Afghanistan	AFG	1953	108919.0	NaN
3	Afghanistan	AFG	1954	111251.0	NaN
4	Afghanistan	AFG	1955	119027.0	NaN

```
In [4]: # Dimensiones del DataFrame
print("Dimensiones (shape):", df.shape)

# Nombres de columnas
print("Columnas:", df.columns.tolist())

# Tipos de datos
print("\nTipos de datos (dtypes):\n", df.dtypes)

# Estadísticas descriptivas generales
print("\nEstadísticas descriptivas:\n", df.describe())

# Valores faltantes por columna
print("\nValores faltantes:\n", df.isnull().sum())
```

```
# Cantidad de entidades únicas
print("\nNúmero de entidades:", df["Entity"].nunique())
```

Dimensiones (shape): (38400, 5)

Columnas: ['Entity', 'Code', 'Year', 'Annual change in population', 'Annual population change (Projected)']

Tipos de datos (dtypes):

```
Entity          str
Code            str
Year            int64
Annual change in population    float64
Annual population change (Projected)  float64
dtype: object
```

Estadísticas descriptivas:

	Year	Annual change in population \
count	38400.000000	1.868800e+04
mean	2025.500000	2.063019e+06
std	43.300872	9.440859e+06
min	1951.000000	-3.315935e+06
25%	1988.000000	1.781000e+03
50%	2025.500000	4.689800e+04
75%	2063.000000	3.021128e+05
max	2100.000000	9.337137e+07

	Annual population change (Projected)
count	1.971200e+04
mean	8.375481e+05
std	5.816745e+06
min	-2.291035e+07
25%	-9.742750e+03
50%	9.350000e+01
75%	1.411160e+05
max	7.206736e+07

Valores faltantes:

```
Entity          0
Code            1200
Year            0
Annual change in population    19712
Annual population change (Projected)  18688
dtype: int64
```

Número de entidades: 256

Preguntas de la Actividad 2

1. ¿Cuántas filas y columnas tiene el dataset?

El dataset contiene **38,400 filas** y **5 columnas** (Entity , Code , Year , Annual change in population y Annual population change (Projected)).

2. ¿Qué tipo de datos contiene la variable Year?

La variable Year contiene datos de tipo **entero (int64)**.

3. ¿Existen valores faltantes?

Sí, existen valores faltantes:

- `Code` tiene 1,200 valores nulos (agrupaciones o regiones sin código ISO estándar).
- `Annual change in population` tiene 19,712 valores nulos (cubre el periodo histórico 1951–2023).
- `Annual population change (Projected)` tiene 18,688 valores nulos (cubre el periodo proyectado 2024–2100).
- `Entity` y `Year` no tienen valores nulos (0 faltantes).

4. ¿Cuántas entidades diferentes contiene el dataset?

El dataset contiene **256 entidades diferentes**.

Filtros y Ejercicios Vistos en Clase

A continuación se incluyen los ejercicios prácticos y filtros de exploración realizados durante la clase:

Filtro 1: Extracción de columnas específicas para el año 2020

```
In [5]: df_2020_ext_columnas1 = df[df["Year"] == 2020][["Entity", "Year"]]
df_2020_ext_columnas1.head(3)
```

```
Out[5]:
```

	Entity	Year
69	Afghanistan	2020
219	Africa (UN)	2020
369	Albania	2020

Filtro 2: Filtrado por rango de años (periodo 2005 a 2020)

```
In [6]: df_2005_2020 = df[(df["Year"] >= 2005) & (df["Year"] <= 2020)]
df_2005_2020.head(3)
```

```
Out[6]:
```

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
54	Afghanistan	AFG	2005	843919.0	NaN
55	Afghanistan	AFG	2006	1019525.0	NaN
56	Afghanistan	AFG	2007	485752.0	NaN

Filtro 3: Filtrado combinado para México entre 2005 y 2020

```
In [7]: df_mexico_2005_2020 = df[(df["Year"] >= 2005) & (df["Year"] <= 2020) & (df["Entity"] == "Mexico")]
print("Dimensiones para México (2005-2020):", df_mexico_2005_2020.shape)
df_mexico_2005_2020.head(3)
```

Dimensiones para México (2005-2020): (16, 5)

Out[7]:

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
22254	Mexico	MEX	2005	1417373.0	NaN
22255	Mexico	MEX	2006	1442162.0	NaN
22256	Mexico	MEX	2007	1520690.0	NaN

Filtro 4: Extracción de columnas de cambio anual para el subconjunto de México

```
In [8]: df_ext_EA = df_mexico_2005_2020[["Entity", "Year", "Annual change in population"]
df_ext_EA.head(3)
```

Out[8]:

	Entity	Year	Annual change in population
22254	Mexico	2005	1417373.0
22255	Mexico	2006	1442162.0
22256	Mexico	2007	1520690.0

Exploración: Listado de entidades únicas presentes en el dataset

```
In [9]: df["Entity"].unique()
```

```
Out[9]: <StringArray>
[      'Afghanistan',      'Africa (UN)',      'Albania',
      'Algeria',      'American Samoa',      'Americas (UN)',
      'Andorra',      'Angola',      'Anguilla',
      'Antigua and Barbuda',
      ...
      'Vanuatu',      'Vatican',      'Venezuela',
      'Vietnam',      'Wallis and Futuna',      'Western Sahara',
      'World',      'Yemen',      'Zambia',
      'Zimbabwe']
Length: 256, dtype: str
```

Actividad 3 — Estadística descriptiva

Propósito

Aplicar medidas estadísticas básicas a una variable poblacional.

Instrucciones

Seleccionamos el año histórico **2020** y calculamos las medidas estadísticas descriptivas sobre la variable `Annual change in population` utilizando Pandas y NumPy.

```
In [10]: # Seleccionar un año del periodo histórico y filtrar los datos correspondientes
year_selected = 2020
df_year = df[df["Year"] == year_selected].copy()
col_target = "Annual change in population"

# Medidas estadísticas descriptivas
```

```

media = df_year[col_target].mean()
mediana = df_year[col_target].median()
varianza = df_year[col_target].var()
desviacion = df_year[col_target].std()
minimo = df_year[col_target].min()
maximo = df_year[col_target].max()

# Identificar entidades con valor mínimo y máximo
entidad_min = df_year.loc[df_year[col_target].idxmin(), "Entity"]
entidad_max = df_year.loc[df_year[col_target].idxmax(), "Entity"]

print(f"--- Estadísticas descriptivas para el año {year_selected} ---")
print(f"Media: {media:,.2f}")
print(f"Mediana: {mediana:,.2f}")
print(f"Varianza: {varianza:,.2f}")
print(f"Desviación estándar: {desviacion:,.2f}")
print(f"Mínimo: {minimo:,.2f} (Entidad: {entidad_min})")
print(f"Máximo: {maximo:,.2f} (Entidad: {entidad_max})")

```

```

--- Estadísticas descriptivas para el año 2020 ---
Media: 2,124,908.85
Mediana: 34,293.50
Varianza: 90,687,335,031,103.64
Desviación estándar: 9,522,989.82
Mínimo: -494,016.00 (Entidad: Venezuela)
Máximo: 75,707,590.00 (Entidad: World)

```

Preguntas de la Actividad 3 (para el año 2020)

1. **¿Cuál es el valor de la media?**

La media es **2,124,908.85** personas.

2. **¿Cuál es el valor de la mediana?**

La mediana es **34,293.50** personas.

3. **¿Cuál es el valor de la desviación estándar?**

La desviación estándar es **9,522,989.82** personas.

4. **¿Qué entidad presenta el valor mínimo y cuál el máximo?**

- **Valor mínimo: Venezuela** con **-494,016** personas.
- **Valor máximo: World** con **75,707,590** personas (a nivel país individual, **India** con 13,871,885 personas).

Actividad 4 — Comprobación del entorno

Propósito

Comprobar que el notebook está utilizando correctamente las herramientas configuradas para la práctica.

```

In [11]: import sys

print("Python:", sys.version)
print("Pandas:", pd.__version__)
print("NumPy:", np.__version__)

```

Python: 3.12.10 (tags/v3.12.10:0cc8128, Apr 8 2025, 12:21:36) [MSC v.1943 64 bit (AMD64)]

Pandas: 3.0.5

NumPy: 2.5.2

Resultados

El análisis, los filtros de clase y la comprobación del entorno se completaron con éxito:

- **Identificación de la fuente:** Se documentó la fuente de los datos (Our World in Data / United Nations World Population Prospects 2024), su cita formal y el significado de las variables.
- **Carga y exploración:** El archivo `annual-population-growth.csv` se cargó correctamente y se exploró su estructura (38,400 registros, 5 columnas, 256 entidades únicas).
- **Filtros de clase:** Se aplicaron filtros por año, intervalos temporales (2005-2020), combinaciones con entidades específicas (México) y selección de columnas.
- **Estadística descriptiva:** Se calcularon satisfactoriamente las medidas descriptivas (media, mediana, varianza, desviación estándar, valores mínimo y máximo) para el año histórico 2020.
- **Comprobación del entorno:** Se verificaron las versiones de las herramientas utilizadas (Python, Pandas y NumPy).